

## De l'intérêt des bibliothèques de *geometry processing* puissantes pour un clustering hiérarchique fin : CGAL, Geogram, etc.

Ce qui leur manque encore pour passer aux interactions d'ordre supérieur.



Présentation à Bruno LÉVY

(Univ. Paris-Saclay, Inria Saclay, CNRS, LMO, Équipe PARMA)

Louis HAUSEUX (Inria Sophia Antipolis, bourse 3IA-DS4H d'Université Côte d'Azur)

Encadré par Konstantin AVRACHENKOV (NEO) & Josiane ZERUBIA (AYANA)



# Plan

**I) Clustering : des statistiques aux graphes**

**II) HDBSCAN & quelques applications en 3D**

**III) Vers des interactions d'ordre supérieur**

**IV) La mosaïque de DELAUNAY d'ordre supérieur**

01

# Clustering : des statistiques aux graphes






# Clustering sur données euclidiennes $X \subset \mathbb{R}^d$



## Modèle de Hartigan [Hartigan, 1981]

- Estimation de la densité  $f$  par  $K$ -NN.
- Définition des **amas de forte densité** (*high-density clusters*) comme composantes connexes des ensembles de niveau de  $f$  [Campello et al., 2013, McInnes and Healy, 2017].
- Seuil de percolation et graphes géométriques aléatoires [Penrose, 2003].



## Exemples d'applications

- **Données réelles** : classification des huiles d'olive italiennes ( $\mathbb{R}^8$ ) [Wickham et al., 2011], où la géographie forme la vérité terrain.
- **Cosmologie** : extraction des filaments galactiques en 3D.



# 02

## HDBSCAN & quelques applications en 3D



# 03

## Vers des interactions d'ordre supérieur



04

# La mosaïque de DELAUNAY d'ordre supérieur



## Références I



Campello, R. J. G. B., Moulavi, D., and Sander, J. (2013).  
Density-based clustering based on hierarchical density estimates.  
*In Advances in Knowledge Discovery and Data Mining*, pages 160–172. Springer.



Hartigan, J. A. (1981).  
Consistency of single linkage for high-density clusters.  
*J. of the Am. Stat. Ass.*, 76(374):388–394.



McInnes, L. and Healy, J. (2017).  
Accelerated hierarchical density based clustering.  
*In IEEE International Conference on Data Mining Workshops (ICDMW)*, pages 33–42.



Penrose, M. (2003).  
*Random Geometric Graphs*, volume 5 of *Oxford Studies in Probability*.  
Oxford University Press.



Wickham, H., Cook, D., Hofmann, H., and Buja, A. (2011).  
tourr: An R package for exploring multivariate data with projections.  
*Journal of Statistical Software*, 40(2):1–18.