

De l'intérêt des bibliothèques de *geometry processing* puissantes pour un clustering hiérarchique fin : CGAL, Geogram, etc.

Ce qui leur manque encore pour passer aux interactions d'ordre supérieur.



Présentation à Bruno LÉVY

(Univ. Paris-Saclay, Inria Saclay, CNRS, LMO, Équipe PARMA)

Louis HAUSEUX (Inria Sophia Antipolis, bourse 3IA-DS4H d'Université Côte d'Azur)

Encadré par Konstantin AVRACHENKOV (NEO) & Josiane ZERUBIA (AYANA)



Plan

I) Clustering : des statistiques aux graphes

II) HDBSCAN & quelques applications en 3D

III) Vers des interactions d'ordre supérieur

IV) La mosaïque de DELAUNAY d'ordre supérieur

01


Clustering : des statistiques aux graphes





Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$

Modèle de Hartigan [5] : Amas de forte densité (*high-density clusters*)



Données brutes $\mathcal{X}$



HDBSCAN¹ [2, 9]




Amas de forte densité

¹ Hierarchical Density-Based Spatial Clustering of Applications with Noise




Quelques exemples



Cosmologie 3D : filaments cosmiques [6]



Quelques exemples




Classification d'huiles d'olive ($\mathcal{X} \subset \mathbb{R}^8$) : résultat hiérarchique [11, 7, 8]



Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$


Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique





Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: estimation

f inconnue



Estimation $\hat{f}$

Méthodes naïves coûteuses
(discrétisation de $\mathbb{R}^d$)



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: estimateur de densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimateur : K plus proches voisins (K -NN)


$$\forall x \in \mathbb{R}^d, \quad \hat{f}_{K\text{-NN}}(x) = \frac{K}{n \omega_d r_K(x)^d}$$

$$r_K(x) = \min \{r \geq 0 \mid |B(x, r) \cap \mathcal{X}| \geq K\}$$

- ▶ n : nombre de points de $\mathcal{X}$
- ▶ ω_d : volume de la boule unité dans $\mathbb{R}^d$
- ▶ $r_K(x)$: distance au K -ième plus proche voisin de x
- ▶ $\omega_d r_K(x)^d$: volume de la boule contenant les K voisins




Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



Nuage de points de Poisson $\mathcal{X} \subset \mathbb{R}^2$



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r\end{aligned}$$

Lignes de niveau de haute densité
= **modèle booléen**



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r\end{aligned}$$

Clusters de haute densité
= **Composantes connexes** de $G(\mathcal{X}, r)$

Graphe géométrique [10]



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$r_1(x) \leq r$$

Clusters de haute densité
= **Composantes connexes** de $G(\mathcal{X}, r)$

Graphe géométrique [10]



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



$$r_1(x) \leq r$$

Clusters de haute densité
= **Composantes connexes** de
 $\text{MST}_r(\mathcal{X})$


Arbre couvrant minimum élagué



L'arbre minimum couvrant et la triangulation de DELAUNAY

L'arbre minimum couvrant euclidien est un sous-graphe de la triangulation de DELAUNAY [1] :

$$\text{MST} \subseteq \text{DELAUNAY}.$$




Dans le plan $\mathbb{R}^2$:

- La triangulation de DELAUNAY possède au plus $3n - 6$ arêtes (complexité linéaire).
- Elle se calcule en $\mathcal{O}(n \log n)$.




Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: clusters de haute densité

- ▶ Si $\hat{f} = \hat{f}_{1\text{-NN}}$: estimateur de densité par 1 plus proche voisin.
- ▶ Construction de l'**arbre minimum couvrant** (MST) :
 - $\mathcal{O}(n^2)$ dans le pire des cas.
 - Optimisations géométriques : $\mathcal{O}(n \log n)$ dans $\mathbb{R}^2$.
- ▶ Algorithmes de clustering :
 - **Single-Linkage** $\longrightarrow$ **HDBSCAN**



Du Single-Linkage au Robust Single-Linkage



Effet de chaînage : Le Single-Linkage classique (1-NN) est très sensible aux bruits qui connectent artificiellement deux amas.

Robust Single-Linkage [3] :

- ▶ Utilise la **distance de cœur** $r_K(x)$ (rayon du K -NN) comme estimateur de densité locale.
- ▶ Remplace la distance géométrique par la **distance d'atteignabilité mutuelle** $d_{\text{mreach}, K}$.
- ▶ Repousse les points isolés dans le bruit en augmentant artificiellement leur distance aux autres points.



Du Robust Single-Linkage à (H)DBSCAN

Limitation du Robust Single-Linkage :

- ▶ Trop exigeant pour les points situés en périphérie des amas.
- ▶ Exclut les points frontières qui ne possèdent pas K voisins, ce qui nuit au rappel des clusters en les rejetant indûment dans le bruit.


DBSCAN [4] (Ester *et al.*, 1996) :

- ▶ Introduit une distinction entre **points cœurs** ($r_K(x) \leq r$) et **points frontières** (accessibles depuis un cœur, mais sans avoir eux-mêmes K voisins).
- ▶ Permet de bien mieux classifier les frontières de clusters, d'où le nom (*Applications with Noise*).

De DBSCAN à HDBSCAN

DBSCAN requiert un seuil global r unique. **HDBSCAN** [2] (Campello *et al.*, 2013) fait varier ce seuil continûment afin de s'affranchir de ce paramètre et de construire une hiérarchie complète.

De DBSCAN à HDBSCAN : l'excès de masse




Excès de masse [2] :

► Stabilité d'un cluster C à λ :

$$E(C) = \int_C (f(x) - \lambda) dx$$

► Correspond aux **aires colorées**.




Aire Violette > Aire Verte + Aire Rouge
 $\Rightarrow$ On garde C_4
(vs. scission C_1 et C_2)




Robust SL / (H)DBSCAN ($K = 2$)

Nuage et boules de rayon r




Arbre hiérarchique






La vraie hiérarchie 2-NN : échelle r

Nuage et boules au niveau r



Arbre hiérarchique




Étape 1 : Les 7 segments fusionnent au seuil r .



La vraie hiérarchie 2-NN : échelle r'

Triangles et 3-intersections à r'



Arbre hiérarchique




Étape 2 : Fusion des triangles à r' via les 3-intersections. CD reste isolé.




La vraie hiérarchie 2-NN : échelle r''

Connexité globale à r''




Arbre hiérarchique




Étape 3 : Connexité globale à r'' par les points de tangence.

Robust SL vs. Vraie hiérarchie 2-NN : Comparaison

Hiérarchie Robust SL ($K = 2$)



Vraie hiérarchie 2-NN




Bilan : La vraie hiérarchie 2-NN isole le pont de liaison C-D, contrairement à Robust SL.



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: clusters de haute densité ($K \geq 2$)

- ▶ Si $\hat{f} = \hat{f}_{K\text{-NN}}$ ($K \geq 2$) : estimateur de densité par K plus proches voisins.
- ▶ Passage aux **hypergraphes** (complexe de Čech $\check{C}(\mathcal{X}, r)$) :
 - Les interactions d'ordre supérieur (arêtes, triangles...) apparaissent aux intersections de boules de rayon r .
- ▶ **Généralisation de la connexité** :
 - Les composantes connexes sont remplacées par les **K -polyèdres** (composantes de $\Gamma_K(\mathcal{X}, r)$).
 - Pour $K \geq 2$, les polyèdres peuvent se recouvrir.
 - **Consistance exacte** avec les amas de densité de $\hat{f}_{K\text{-NN}}$ (thèse Louis Hauseux).



02

HDBSCAN & quelques applications en 3D



03

Vers des interactions d'ordre supérieur



04

La mosaïque de DELAUNAY d'ordre supérieur



Références I



Jean-Daniel Boissonnat, Frédéric Chazal, and Mariette Yvinec.

Geometric and Topological Inference.

Cambridge Texts in Applied Mathematics. Cambridge University Press, 2018.



Ricardo J. G. B. Campello, Davoud Moulavi, and Joerg Sander.

Density-based clustering based on hierarchical density estimates.

In *Advances in Knowledge Discovery and Data Mining*, pages 160–172. Springer, 2013.



Kamalika Chaudhuri and Sanjoy Dasgupta.

Rates of convergence for the cluster tree.

In *Advances in Neural Information Processing Systems*, volume 23, pages 343–351. Curran Associates, Inc., 2010.



Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu.

A density-based algorithm for discovering clusters in large spatial databases with noise.

In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, KDD'96, page 226–231. AAAI Press, 1996.

Références II



John A. Hartigan.

Consistency of single linkage for high-density clusters.

J. of the Am. Stat. Ass., 76(374):388–394, 1981.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.

Graph based approach for galaxy filament extraction.

In *Complex Networks & Their Applications XII*, pages 384–396. Springer, 2023.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.

Benefits of hypergraphs for density-based clustering.

In *32nd European Signal Processing Conference (EUSIPCO)*, Lyon, France, August 2024.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.

Generalization of single-linkage with higher-order interactions.

Applied Network Science, 11(1):9, 2026.



Leland McInnes and John Healy.

Accelerated hierarchical density based clustering.

In *IEEE International Conference on Data Mining Workshops (ICDMW)*, pages 33–42, 2017.

Références III



Mathew Penrose.

Random Geometric Graphs, volume 5 of *Oxford Studies in Probability*.
Oxford University Press, 2003.



Hadley Wickham, Dianne Cook, Heike Hofmann, and Andreas Buja.

tourr: An R package for exploring multivariate data with projections.
Journal of Statistical Software, 40(2):1–18, 2011.