

## De l'intérêt des bibliothèques de *geometry processing* puissantes pour un clustering hiérarchique fin : CGAL, Geogram, etc.

Ce qui leur manque encore pour passer aux interactions d'ordre supérieur.



Présentation à Bruno LÉVY

(Univ. Paris-Saclay, Inria Saclay, CNRS, LMO, Équipe PARMA)

Louis HAUSEUX (Inria Sophia Antipolis, bourse 3IA-DS4H d'Université Côte d'Azur)

Encadré par Konstantin AVRACHENKOV (NEO) & Josiane ZERUBIA (AYANA)

- I) Clustering : des statistiques aux graphes**
- II) HDBSCAN & quelques applications en 3D**
- III) Vers des interactions d'ordre supérieur**
- IV) La mosaïque de DELAUNAY d'ordre supérieur**

01


# Clustering : des statistiques aux graphes





## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$

Modèle de Hartigan [3] : Amas de forte densité (*high-density clusters*)



Données brutes  $\mathcal{X}$



HDBSCAN<sup>1</sup> [2, 7]




Amas de forte densité

<sup>1</sup> Hierarchical Density-Based Spatial Clustering of Applications with Noise




## Quelques exemples



**Cosmologie 3D : filaments cosmiques [4]**

## Quelques exemples




**Classification d'huiles d'olive ( $\mathcal{X} \subset \mathbb{R}^8$ ) : résultat hiérarchique [9, 5, 6]**



## Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau  $\{f \geq \lambda\}$


Arbre hiérarchique






## Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau  $\{f \geq \lambda\}$



Arbre hiérarchique









## Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau  $\{f \geq \lambda\}$




Arbre hiérarchique






## Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau  $\{f \geq \lambda\}$



Arbre hiérarchique





## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : estimation

$f$  inconnue



**Estimation  $\hat{f}$**

Méthodes naïves coûteuses  
(discrétisation de  $\mathbb{R}^d$ )



## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : estimateur de densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

**Estimateur** :  $K$  plus proches voisins ( $K$ -NN)


$$\forall x \in \mathbb{R}^d, \quad \hat{f}_{K\text{-NN}}(x) = \frac{K}{n \omega_d r_K(x)^d}$$

$$r_K(x) = \min \{r \geq 0 \mid |B(x, r) \cap \mathcal{X}| \geq K\}$$

- ▶  $n$  : nombre de points de  $\mathcal{X}$
- ▶  $\omega_d$  : volume de la boule unité dans  $\mathbb{R}^d$
- ▶  $r_K(x)$  : distance au  $K$ -ième plus proche voisin de  $x$
- ▶  $\omega_d r_K(x)^d$  : volume de la boule contenant les  $K$  voisins




## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 1$



Nuage de points de Poisson  $\mathcal{X} \subset \mathbb{R}^2$



## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r\end{aligned}$$

Lignes de niveau de haute densité  
= **modèle booléen**



## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r\end{aligned}$$

Clusters de haute densité  
= **Composantes connexes** de  $G(\mathcal{X}, r)$

**Graphe géométrique** [8]



## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 1$



$$r_1(x) \leq r$$


Clusters de haute densité  
= **Composantes connexes** de  $G(\mathcal{X}, r)$

**Graphe géométrique** [8]





## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 1$



$$r_1(x) \leq r$$

Clusters de haute densité  
= **Composantes connexes** de  
 $\text{MST}_r(\mathcal{X})$


**Arbre couvrant minimum élagué**



## L'arbre minimum couvrant et la triangulation de DELAUNAY

**L'arbre minimum couvrant euclidien** est un sous-graphe de la triangulation de DELAUNAY [1] :

$$\text{MST} \subseteq \text{DELAUNAY}.$$




Dans le plan  $\mathbb{R}^2$  :

- La triangulation de DELAUNAY possède au plus  $3n - 6$  arêtes (complexité linéaire).
- Elle se calcule en  $\mathcal{O}(n \log n)$ .




## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : clusters de haute densité

- ▶ Si  $\hat{f} = \hat{f}_{1\text{-NN}}$  : estimateur de densité par 1 plus proche voisin.
- ▶ Construction de l'**arbre minimum couvrant** (MST) :
  - $\mathcal{O}(n^2)$  dans le pire des cas.
  - Optimisations géométriques :  $\mathcal{O}(n \log n)$  dans  $\mathbb{R}^2$ .
- ▶ Algorithmes de clustering :
  - **Single-Linkage**  $\rightarrow$  **HDBSCAN**






## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 2$



Nuage de points de Poisson  $\mathcal{X} \subset \mathbb{R}^2$



## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 2$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_2(x) &\leq r\end{aligned}$$

Lignes de niveau de haute densité  
= **2-intersections de boules**



## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 2$




$$\hat{\lambda}(x) \geq \lambda_0 \\ \Leftrightarrow r_2(x) \leq r$$

Clusters de haute densité  
= **Composantes connexes** de  $\Gamma_2(\mathcal{X}, r)$

**2-intersections** reliées par des  
**3-intersections** (triangles)



## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 2$




$$r_2(x) \leq r$$

Clusters de haute densité  
= **Composantes connexes** de  $\Gamma_2(\mathcal{X}, r)$

**Connexité par triangles**



## Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$ : le cas $K = 2$



$$r_2(x) \leq r$$

Clusters de haute densité  
= **Composantes connexes** de  
 $\text{HGP}_r(\mathcal{X})$

**Graphe géométrique d'ordre 2  
élagué**





# L'arbre minimum couvrant et la triangulation de DELAUNAY

# 02

## HDBSCAN & quelques applications en 3D



# 03

## Vers des interactions d'ordre supérieur



04

# La mosaïque de DELAUNAY d'ordre supérieur



## Références I



Jean-Daniel Boissonnat, Frédéric Chazal, and Mariette Yvinec.

*Geometric and Topological Inference.*

Cambridge Texts in Applied Mathematics. Cambridge University Press, 2018.



Ricardo J. G. B. Campello, Davoud Moulavi, and Joerg Sander.

Density-based clustering based on hierarchical density estimates.

In *Advances in Knowledge Discovery and Data Mining*, pages 160–172. Springer, 2013.



John A. Hartigan.

Consistency of single linkage for high-density clusters.

*J. of the Am. Stat. Ass.*, 76(374):388–394, 1981.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.

Graph based approach for galaxy filament extraction.

In *Complex Networks & Their Applications XII*, pages 384–396. Springer, 2023.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.

Benefits of hypergraphs for density-based clustering.

In *32nd European Signal Processing Conference (EUSIPCO)*, Lyon, France, August 2024.

## Références II



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.  
Generalization of single-linkage with higher-order interactions.  
*Applied Network Science*, 11(1):9, 2026.



Leland McInnes and John Healy.  
Accelerated hierarchical density based clustering.  
In *IEEE International Conference on Data Mining Workshops (ICDMW)*, pages 33–42, 2017.



Mathew Penrose.  
*Random Geometric Graphs*, volume 5 of *Oxford Studies in Probability*.  
Oxford University Press, 2003.



Hadley Wickham, Dianne Cook, Heike Hofmann, and Andreas Buja.  
tourr: An R package for exploring multivariate data with projections.  
*Journal of Statistical Software*, 40(2):1–18, 2011.