

De l'intérêt des bibliothèques de *geometry processing* puissantes pour un clustering hiérarchique fin : CGAL, Geogram, etc.

Ce qui leur manque encore pour passer aux interactions d'ordre supérieur.



Présentation à Bruno LÉVY

(Univ. Paris-Saclay, Inria Saclay, CNRS, LMO, Équipe PARMA)

Louis HAUSEUX (Inria Sophia Antipolis, bourse 3IA-DS4H d'Université Côte d'Azur)

Encadré par Konstantin AVRACHENKOV (NEO) & Josiane ZERUBIA (AYANA)

- I) Clustering : des statistiques aux graphes**
- II) HDBSCAN & quelques applications en 3D**
- III) Vers des interactions d'ordre supérieur**
- IV) La mosaïque de DELAUNAY d'ordre supérieur**

01


Clustering : des statistiques aux graphes





Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$

Modèle de Hartigan [3] : Amas de forte densité (*high-density clusters*)



Données brutes $\mathcal{X}$



HDBSCAN¹ [2, 7]




Amas de forte densité

¹ Hierarchical Density-Based Spatial Clustering of Applications with Noise




Quelques exemples



Cosmologie 3D : filaments cosmiques [4]

Quelques exemples




Classification d'huiles d'olive ($\mathcal{X} \subset \mathbb{R}^8$) : résultat hiérarchique [9, 5, 6]



Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$


Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique





Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: estimation

f inconnue



Estimation $\hat{f}$

Méthodes naïves coûteuses
(discrétisation de $\mathbb{R}^d$)



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: estimateur de densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimateur : K plus proches voisins (K -NN)


$$\forall x \in \mathbb{R}^d, \quad \hat{f}_{K\text{-NN}}(x) = \frac{K}{n \omega_d r_K(x)^d}$$

$$r_K(x) = \min \{r \geq 0 \mid |B(x, r) \cap \mathcal{X}| \geq K\}$$

- ▶ n : nombre de points de $\mathcal{X}$
- ▶ ω_d : volume de la boule unité dans $\mathbb{R}^d$
- ▶ $r_K(x)$: distance au K -ième plus proche voisin de x
- ▶ $\omega_d r_K(x)^d$: volume de la boule contenant les K voisins




Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



Nuage de points de Poisson $\mathcal{X} \subset \mathbb{R}^2$



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r\end{aligned}$$

Lignes de niveau de haute densité
= **modèle booléen**



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r\end{aligned}$$

Clusters de haute densité
= **Composantes connexes** de $G(\mathcal{X}, r)$

Graphe géométrique [8]



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$r_1(x) \leq r$$

Clusters de haute densité
= **Composantes connexes** de $G(\mathcal{X}, r)$

Graphe géométrique [8]



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



$$r_1(x) \leq r$$

Clusters de haute densité
= **Composantes connexes** de
 $\text{MST}_r(\mathcal{X})$


Arbre couvrant minimum élagué



L'arbre minimum couvrant et la triangulation de DELAUNAY

L'arbre minimum couvrant euclidien est un sous-graphe de la triangulation de DELAUNAY [1] :

$$\text{MST} \subseteq \text{DELAUNAY}.$$




Dans le plan $\mathbb{R}^2$:

- ▶ La triangulation de DELAUNAY possède au plus $3n - 6$ arêtes (complexité linéaire).
- ▶ Elle se calcule en $\mathcal{O}(n \log n)$.




Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: clusters de haute densité

- ▶ Si $\hat{f} = \hat{f}_{1-\text{NN}}$: estimateur de densité par 1 plus proche voisin.
- ▶ Construction de l'**arbre minimum couvrant** (MST) :
 - $\mathcal{O}(n^2)$ dans le pire des cas.
 - Optimisations géométriques : $\mathcal{O}(n \log n)$ dans $\mathbb{R}^2$.
- ▶ Algorithmes de clustering :
 - **Single-Linkage** $\rightarrow$ **HDBSCAN**



Du Single-Linkage au Robust Single-Linkage




Effet de chaînage : Le Single-Linkage classique (1-NN) est très sensible aux bruits qui connectent artificiellement deux amas.

Robust Single-Linkage :

- ▶ Utilise la **distance de cœur** $r_K(x)$ (rayon du K -NN) comme estimateur de densité locale.
- ▶ Remplace la distance géométrique par la **distance d'atteignabilité mutuelle** $d_{\text{mreach}, K}$.
- ▶ Repousse les points isolés dans le bruit en augmentant artificiellement leur distance aux autres points.



Du Robust Single-Linkage à (H)DBSCAN



DBSCAN (Ester *et al.*, 1996) à un seuil r :



- **Point cœur** (A) : possède $\geq K$ voisins dans son rayon r ($r_K(x) \leq r$).
- **Point frontière** (B) : proche de A , mais possède $< K$ voisins.
- **Bruit** (C) : ni cœur, ni frontière.

De DBSCAN à HDBSCAN

DBSCAN requiert un seuil global r unique.

HDBSCAN fait varier ce seuil continûment pour construire une hiérarchie complète sans paramètre d'échelle.

De DBSCAN à HDBSCAN : l'excès de masse



Excès de masse [2] :

- Mesure la stabilité d'un cluster C à la densité λ :

$$E(C) = \int_C (f(x) - \lambda) dx$$

- Correspond aux **aires colorées**.


Simplification

De bas en haut :

- Si la stabilité cumulée des enfants est supérieure à celle du parent, on garde la scission.
- Sinon, le parent absorbe les enfants.



Robust SL / (H)DBSCAN vs. Hiérarchie exacte 2-NN




Robust SL / (H)DBSCAN ($K = 2$) :

- ▶ Seuil d'atteignabilité mutuelle $d_{\text{mreach},2} = 2r$.
- ▶ Tous les points ont au moins $K = 2$ voisins à distance $2r$ (leurs cercles de rayon r se touchent).
- ▶ Les 6 points fusionnent **simultanément** en un unique composant.
- ▶ Incapacité à séparer les deux triangles du pont de liaison $C-D$.



Robust SL / (H)DBSCAN vs. Hiérarchie exacte 2-NN



La vraie hiérarchie 2-NN :

- ▶ À la résolution $r' = \frac{2\sqrt{3}}{3}r \approx 1.15r$, les boules s'intersectent trois à trois aux centres des triangles (points rouges).
- ▶ Les deux triangles gauche et droit forment chacun un cluster séparé.
- ▶ Le segment central $C-D$ reste **isolé** (pas de 3-intersection pour le connecter).
- ▶ Permet de séparer les deux structures de forte densité du pont de bruit.

02

HDBSCAN & quelques applications en 3D



03

Vers des interactions d'ordre supérieur



04

La mosaïque de DELAUNAY d'ordre supérieur



Références I



Jean-Daniel Boissonnat, Frédéric Chazal, and Mariette Yvinec.

Geometric and Topological Inference.

Cambridge Texts in Applied Mathematics. Cambridge University Press, 2018.



Ricardo J. G. B. Campello, Davoud Moulavi, and Joerg Sander.

Density-based clustering based on hierarchical density estimates.

In *Advances in Knowledge Discovery and Data Mining*, pages 160–172. Springer, 2013.



John A. Hartigan.

Consistency of single linkage for high-density clusters.

J. of the Am. Stat. Ass., 76(374):388–394, 1981.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.

Graph based approach for galaxy filament extraction.

In *Complex Networks & Their Applications XII*, pages 384–396. Springer, 2023.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.

Benefits of hypergraphs for density-based clustering.

In *32nd European Signal Processing Conference (EUSIPCO)*, Lyon, France, August 2024.

Références II



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.
Generalization of single-linkage with higher-order interactions.
Applied Network Science, 11(1):9, 2026.



Leland McInnes and John Healy.
Accelerated hierarchical density based clustering.
In *IEEE International Conference on Data Mining Workshops (ICDMW)*, pages 33–42, 2017.



Mathew Penrose.
Random Geometric Graphs, volume 5 of *Oxford Studies in Probability*.
Oxford University Press, 2003.



Hadley Wickham, Dianne Cook, Heike Hofmann, and Andreas Buja.
tourr: An R package for exploring multivariate data with projections.
Journal of Statistical Software, 40(2):1–18, 2011.