

De l'intérêt des bibliothèques de *geometry processing* puissantes pour un clustering hiérarchique fin : CGAL, Geogram, etc.

Ce qui leur manque encore pour passer aux interactions d'ordre supérieur.



Présentation à Bruno LÉVY

(Univ. Paris-Saclay, Inria Saclay, CNRS, LMO, Équipe PARMA)

Louis HAUSEUX (Inria Sophia Antipolis, bourse 3IA-DS4H d'Université Côte d'Azur)

Encadré par Konstantin AVRACHENKOV (NEO) & Josiane ZERUBIA (AYANA)



Plan

I) Clustering : des statistiques aux graphes

II) HDBSCAN & quelques applications en 3D

III) Vers des interactions d'ordre supérieur

IV) La mosaïque de DELAUNAY d'ordre supérieur

01


Clustering : des statistiques aux graphes





Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$

Modèle de Hartigan [3] : Amas de forte densité (*high-density clusters*)



Données brutes $\mathcal{X}$



HDBSCAN¹ [2, 7]




Amas de forte densité

¹ Hierarchical Density-Based Spatial Clustering of Applications with Noise




Quelques exemples



Cosmologie 3D : filaments cosmiques [4]

Quelques exemples




Classification d'huiles d'olive ($\mathcal{X} \subset \mathbb{R}^8$) : résultat hiérarchique [9, 5, 6]



Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$

Arbre hiérarchique




C_1






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique





Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: estimation

f inconnue



Estimation $\hat{f}$

Méthodes naïves coûteuses
(discrétisation de $\mathbb{R}^d$)



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: estimateur de densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimateur : K plus proches voisins (K -NN)


$$\forall x \in \mathbb{R}^d, \quad \hat{f}_{K\text{-NN}}(x) = \frac{K}{n \omega_d r_K(x)^d}$$

$$r_K(x) = \min \{r \geq 0 \mid |B(x, r) \cap \mathcal{X}| \geq K\}$$

- ▶ n : nombre de points de $\mathcal{X}$
- ▶ ω_d : volume de la boule unité dans $\mathbb{R}^d$
- ▶ $r_K(x)$: distance au K -ième plus proche voisin de x
- ▶ $\omega_d r_K(x)^d$: volume de la boule contenant les K voisins




Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



Nuage de points de Poisson $\mathcal{X} \subset \mathbb{R}^2$



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r\end{aligned}$$

Lignes de niveau de haute densité
= **modèle booléen**



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r\end{aligned}$$

Clusters de haute densité
= **Composantes connexes** de $G(\mathcal{X}, r)$

Graphe géométrique [8]



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$r_1(x) \leq r$$

Clusters de haute densité
= **Composantes connexes** de $G(\mathcal{X}, r)$

Graphe géométrique [8]



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



$$r_1(x) \leq r$$

Clusters de haute densité
= **Composantes connexes** de
 $\text{MST}_r(\mathcal{X})$


Arbre couvrant minimum élagué



L'arbre minimum couvrant et la triangulation de DELAUNAY

L'arbre minimum couvrant euclidien est un sous-graphe de la triangulation de DELAUNAY [1] :

$$\text{MST} \subseteq \text{DELAUNAY}.$$




Dans le plan $\mathbb{R}^2$:

- La triangulation de DELAUNAY possède au plus $3n - 6$ arêtes (complexité linéaire).
- Elle se calcule en $\mathcal{O}(n \log n)$.



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: clusters de haute densité

- ▶ Si $\hat{f} = \hat{f}_{1-\text{NN}}$: estimateur de densité par 1 plus proche voisin.
- ▶ Construction de l'**arbre minimum couvrant** (MST) :
 - $\mathcal{O}(n^2)$ dans le pire des cas.
 - Optimisations géométriques : $\mathcal{O}(n \log n)$ dans $\mathbb{R}^2$.
- ▶ Algorithmes de clustering :
 - **Single-Linkage** $\rightarrow$ **HDBSCAN**



Du Single-Linkage au Robust Single-Linkage

Le **Single-Linkage** classique (1-NN) souffre de l'*effet de chaîne* : une seule observation de bruit peut fusionner deux amas distincts.

Robust Single-Linkage (Chaudhuri & Dasgupta, 2010) :

- ▶ Substitue l'estimateur de densité 1-NN par le **K-NN**.

- ▶ **Distance de cœur** (*core distance*) $r_K(x)$:

$$r_K(x) = \min\{r \geq 0 \mid |B(x, r) \cap \mathcal{X}| \geq K\}$$

- ▶ **Distance d'atteignabilité mutuelle** :

$$d_{\text{mreach},K}(x, y) = \max\{r_K(x), r_K(y), d(x, y)\}$$

Algorithme

On applique le Single-Linkage (extraction de l'arbre couvrant minimum, MST) sur le graphe complet pondéré par la métrique $d_{\text{mreach},K}$.

- ▶ Deux points ne se connectent à une échelle r que s'ils sont géométriquement proches **et** situés dans des régions de forte densité ($r_K(x), r_K(y) \leq r$).
- ▶ Consistance mathématique robuste démontrée lorsque $K \rightarrow \infty$.



Du Robust Single-Linkage à (H)DBSCAN

Limitation du Robust Single-Linkage :

- ▶ Trop exigeant pour les points frontières (qui n'ont pas K voisins).
- ▶ Ceux-ci sont rejetés dans le bruit, ce qui nuit au rappel des clusters.

DBSCAN (Ester *et al.*, 1996) à un seuil r :

- ▶ **Points cœurs** : $r_K(x) \leq r$ (au moins K voisins).
- ▶ **Points accessibles** (frontières) : $r_K(x) > r$, mais à distance $\leq r$ d'un point cœur.
- ▶ **Bruit** : tous les autres points.

De DBSCAN à HDBSCAN

DBSCAN requiert un seuil global r unique, inadapté aux densités variables.

HDBSCAN (Campello *et al.*, 2013) :

- ▶ Fait varier le seuil r continûment pour construire une hiérarchie complète.
- ▶ Utilise la distance d'atteignabilité mutuelle $d_{\text{mreach}, K}$.
- ▶ Extrait la hiérarchie simplifiée via l'excès de masse.


Du DBSCAN à HDBSCAN : l'excès de masse

Excès de masse (*excess of mass*) [2] :

- Mesure la stabilité d'un cluster C apparu à une densité λ :

$$E(C) = \int_C (f(x) - \lambda) \mathbf{1}_{f(x) \geq \lambda} dx$$

- Graphiquement, cela correspond aux **aires colorées** sous la courbe.




Simplification de l'arbre

De bas en haut dans l'arbre condensé :

- Si $\sum \text{Stabilité}(\text{Enfants}) > \text{Stabilité}(\text{Parent})$, on garde la scission.
- Sinon, le parent absorbe les enfants.
- Extraction finale optimale (C_1, C_2, C_3).



Robust SL / (H)DBSCAN vs. Hiérarchie exacte 2-NN




Robust SL / (H)DBSCAN ($K = 2$) :

- ▶ Seuil d'atteignabilité mutuelle $d_{\text{mreach},2} = 2r$.
- ▶ Tous les points ont au moins $K = 2$ voisins à distance $2r$ (leurs cercles de rayon r se touchent).
- ▶ Les 6 points fusionnent **simultanément** en un unique composant.
- ▶ Incapacité à séparer les deux triangles du pont de liaison $C-D$.



Robust SL / (H)DBSCAN vs. Hiérarchie exacte 2-NN



La vraie hiérarchie 2-NN :

- ▶ À la résolution $r' = \frac{2\sqrt{3}}{3}r \approx 1.15r$, les boules s'intersectent trois à trois aux centres des triangles (points rouges).
- ▶ Les deux triangles gauche et droit forment chacun un cluster séparé.
- ▶ Le segment central $C-D$ reste **isolé** (pas de 3-intersection pour le connecter).
- ▶ Permet de séparer les deux structures de forte densité du pont de bruit.

02

HDBSCAN & quelques applications en 3D



03

Vers des interactions d'ordre supérieur



04

La mosaïque de DELAUNAY d'ordre supérieur



Références I



Jean-Daniel Boissonnat, Frédéric Chazal, and Mariette Yvinec.

Geometric and Topological Inference.

Cambridge Texts in Applied Mathematics. Cambridge University Press, 2018.



Ricardo J. G. B. Campello, Davoud Moulavi, and Joerg Sander.

Density-based clustering based on hierarchical density estimates.

In *Advances in Knowledge Discovery and Data Mining*, pages 160–172. Springer, 2013.



John A. Hartigan.

Consistency of single linkage for high-density clusters.

J. of the Am. Stat. Ass., 76(374):388–394, 1981.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.

Graph based approach for galaxy filament extraction.

In *Complex Networks & Their Applications XII*, pages 384–396. Springer, 2023.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.

Benefits of hypergraphs for density-based clustering.

In *32nd European Signal Processing Conference (EUSIPCO)*, Lyon, France, August 2024.

Références II



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.
Generalization of single-linkage with higher-order interactions.
Applied Network Science, 11(1):9, 2026.



Leland McInnes and John Healy.
Accelerated hierarchical density based clustering.
In *IEEE International Conference on Data Mining Workshops (ICDMW)*, pages 33–42, 2017.



Mathew Penrose.
Random Geometric Graphs, volume 5 of *Oxford Studies in Probability*.
Oxford University Press, 2003.



Hadley Wickham, Dianne Cook, Heike Hofmann, and Andreas Buja.
tourr: An R package for exploring multivariate data with projections.
Journal of Statistical Software, 40(2):1–18, 2011.