

De l'intérêt des bibliothèques de *geometry processing* puissantes pour un clustering hiérarchique fin : CGAL, Geogram, etc.

Ce qui leur manque encore pour passer aux interactions d'ordre supérieur.



Présentation à Bruno LÉVY

(Univ. Paris-Saclay, Inria Saclay, CNRS, LMO, Équipe PARMA)

Louis HAUSEUX (Inria Sophia Antipolis, bourse 3IA-DS4H d'Université Côte d'Azur)

Encadré par Konstantin AVRACHENKOV (NEO) & Josiane ZERUBIA (AYANA)



Plan

- I) Clustering : des statistiques aux graphes**
- II) HDBSCAN & quelques applications en 3D**
- III) Vers des interactions d'ordre supérieur**
- IV) La mosaïque de DELAUNAY d'ordre supérieur**

01


Clustering : des statistiques aux graphes





Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$


Modèle de Hartigan [2] : Amas de forte densité (*high-density clusters*)



Données brutes $\mathcal{X}$



HDBSCAN¹ [1, 6]




Amas de forte densité

¹ Hierarchical Density-Based Spatial Clustering of Applications with Noise




Quelques exemples



Cosmologie 3D : filaments cosmiques [3]

Quelques exemples




Classification d'huiles d'olive ($\mathcal{X} \subset \mathbb{R}^8$) : résultat hiérarchique [7, 4, 5]



Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$


Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique






Modèle de Hartigan : hiérarchie des amas de forte densité

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique





Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: estimation

f inconnue



Estimation $\hat{f}$

Méthodes naïves coûteuses
(discrétisation de $\mathbb{R}^d$)



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: estimateur de densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimateur : K plus proches voisins (K -NN)


$$\forall x \in \mathbb{R}^d, \quad \hat{f}_{K\text{-NN}}(x) = \frac{K}{n \omega_d r_K(x)^d}$$

$$r_K(x) = \min \{r \geq 0 \mid |B(x, r) \cap \mathcal{X}| \geq K\}$$

- ▶ n : nombre de points de $\mathcal{X}$
- ▶ ω_d : volume de la boule unité dans $\mathbb{R}^d$
- ▶ $r_K(x)$: distance au K -ième plus proche voisin de x
- ▶ $\omega_d r_K(x)^d$: volume de la boule contenant les K voisins




Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



Nuage de points de Poisson $\mathcal{X} \subset \mathbb{R}^2$



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r\end{aligned}$$

Lignes de niveau de haute densité
= **modèle booléen**



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



$$\hat{\lambda}(x) \geq \lambda_0$$
$$\Leftrightarrow r_1(x) \leq r$$


Clusters de haute densité
= **Composantes connexes** de $G(\mathcal{X}, r)$



Graphe géométrique



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



$$r_1(x) \leq r$$


Clusters de haute densité
= **Composantes connexes** de $G(\mathcal{X}, r)$



Graphe géométrique



Clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^d$: le cas $K = 1$



$$r_1(x) \leq r$$

Clusters de haute densité
= **Composantes connexes** de
 $\text{MST}_r(\mathcal{X})$



Arbre couvrant minimum élagué

02

HDBSCAN & quelques applications en 3D



03

Vers des interactions d'ordre supérieur



04

La mosaïque de DELAUNAY d'ordre supérieur



Références I



Ricardo J. G. B. Campello, Davoud Moulavi, and Joerg Sander.
Density-based clustering based on hierarchical density estimates.
In Advances in Knowledge Discovery and Data Mining, pages 160–172. Springer, 2013.



John A. Hartigan.
Consistency of single linkage for high-density clusters.
J. of the Am. Stat. Ass., 76(374):388–394, 1981.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.
Graph based approach for galaxy filament extraction.
In Complex Networks & Their Applications XII, pages 384–396. Springer, 2023.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.
Benefits of hypergraphs for density-based clustering.
In 32nd European Signal Processing Conference (EUSIPCO), Lyon, France, August 2024.



Louis Hauseux, Konstantin Avrachenkov, and Josiane Zerubia.
Generalization of single-linkage with higher-order interactions.
Applied Network Science, 11(1):9, 2026.

Références II



Leland McInnes and John Healy.

Accelerated hierarchical density based clustering.

In *IEEE International Conference on Data Mining Workshops (ICDMW)*, pages 33–42, 2017.



Hadley Wickham, Dianne Cook, Heike Hofmann, and Andreas Buja.

tourr: An R package for exploring multivariate data with projections.

Journal of Statistical Software, 40(2):1–18, 2011.